

Laboratório de Bioinformática
IQ-USP

Roteiros Práticos de Bioinformática (QBQ5722)

Da comparação de sequências à análise de
microbiomas

Guillermo Uceda Campos

Suzana Eiko Sato Guima

João Carlos Setubal

São Paulo - SP

2026

Sumário

Apresentação	1
Estrutura dos Roteiros	2
Primeiros Passos	3
Roteiro 1: Algoritmos, Ferramentas e Pipelines	5
Roteiro 2: Comparação de Sequências Biológicas	16

Apresentação

Este material foi desenvolvido a partir das atividades realizadas no Laboratório de Bioinformática do Instituto de Química da Universidade de São Paulo, como um recurso didático organizado em roteiros. Seu principal objetivo é oferecer uma formação prática introdutória em bioinformática e incentivar a participação ativa dos estudantes, centrada no uso de ferramentas e workflows para a análise de sequências biológicas, com base em dados reais de genes, genomas e metagenomas

Para isso, os roteiros orientam, de forma guiada e passo a passo, a realização de exercícios progressivos. Nesses exercícios, os estudantes executam análises reproduzíveis utilizando ferramentas bioinformáticas e configurando seus parâmetros básicos, com aumento gradual de complexidade. Ao longo da prática, são integradas perguntas para reforçar a compreensão, além de acompanhamento em sala para esclarecimento de dúvidas.

Espera-se que os estudantes desenvolvam compreensão do uso de ferramentas bioinformáticas sob a perspectiva do usuário, sendo capazes de aplicá-las na análise de dados em contextos distintos dos apresentados nos roteiros, bem como explorar e propor interpretações a partir dos resultados obtidos.

Os roteiros utilizam diferentes plataformas e ferramentas, sendo a plataforma Galaxy utilizada com maior frequência devido à sua interface intuitiva. Isso facilita o primeiro contato com a área e permite a integração de diferentes ferramentas e a organização de análises em workflows em um único ambiente.

Por fim, para os estudantes que desejarem aprofundar seus estudos, o material oferece sugestões adicionais, que poderão ser revisitadas conforme considerarem mais adequado.

Estrutura dos roteiros

Cada roteiro segue uma estrutura padrão, descrita a seguir:

- **Título e subtítulo**, que contextualizam o tema do roteiro.
- **Leitura introdutória**, apresentada por meio de uma breve metáfora, história ou exemplo científico, com a finalidade de motivar o estudante e introduzir o tema.
- **Objetivos de aprendizagem**, que indicam de forma clara o que se espera que o estudante seja capaz de executar e aplicar ao final do roteiro.
- **Conceitos prévios**, que correspondem a uma breve revisão de conceitos necessários para a realização das atividades propostas no roteiro.
- **Guia passo a passo**, instruções que orientam o estudante na execução das atividades propostas no roteiro. Essas instruções organizam as atividades em etapas numeradas (1, 2, 3, ...), cada uma composta por passos sequenciais: a), b), c), Entre os passos, podem ser incluídos:

Explicativos, com observações sobre o funcionamento das ferramentas, dicas práticas e comentários que auxiliam o aprendizado.

Perguntas, inseridas ao longo das etapas para orientar a descrição e a análise dos resultados, além de estimular a interpretação crítica dos dados.

Caixas de parâmetros, solicitados pelas ferramentas e seus respectivos valores. Por exemplo:

Arquivo de entrada: sequencia1.fasta

Parâmetro A: 0.5

Arquivo de saída: resultado.txt

▶ ***Run Tool:***

Pseudocódigo, para visualizar conceitos computacionais sem exigir conhecimento prévio de programação.


Código, trechos de código em Python explicados para ilustrar sua aplicação prática.

- **Relatório final**, que o aluno entregará ao final de cada aula. Esse deve conter as respostas às perguntas propostas ao longo do guia passo a passo.

Primeiros Passos

- **Acesso ao repositório do Laboratório de Bioinformática**

O Laboratório de Bioinformática do Instituto de Química da USP, conhecido como Setulab, mantém um repositório no GitHub, que pode ser acessado por meio do seguinte link: [GitHub-Setulab](#)



Repositório Setulab - acessado 26 em abril de 2026.

O GitHub é uma plataforma online utilizada para armazenar, organizar e compartilhar arquivos, permitindo também acompanhar as atualizações do material.


- **Organização do repositório da disciplina**

O repositório da disciplina QBQ5722 pode ser acessado por meio do link: [GitHub-Setulab-bioinformaticsCourse](#)

A organização do repositório está estruturada em pastas para cada roteiro (**roteiro1**, **roteiro2**, ...), nas quais se encontra o material utilizado em cada atividade. Isso inclui o documento principal “**RoteirosBioinfo.pdf**”, que reúne o guia passo a passo de todos os roteiros. Para acessar esse material, recomenda-se baixar a pasta completa de cada roteiro utilizando a ferramenta [Download-directory.github](#). Para isso, copie o link da pasta desejada, cole-o na caixa de entrada ferramenta e realize o download no formato .zip. Em seguida, descompacte o arquivo em seu computador.

- **Conhecendo o Galaxy**

O Galaxy é uma plataforma de bioinformática que facilita a análise de dados biológicos por meio de uma interface web intuitiva. É amplamente utilizada em áreas como genômica, transcriptômica e metagenômica, pois reúne diversas ferramentas em um único ambiente. A plataforma permite executar análises e construir fluxos de trabalho (workflows), dispensando a necessidade de conhecimentos avançados de programação.




Plataforma Galaxy - acessada em 26 abril de 2026.

- Criação de uma conta no Galaxy


Para utilizar a plataforma Galaxy, é necessário criar uma conta. No canto superior direito do site <https://usegalaxy.eu/>, selecione “Register” no primeiro acesso e informe um e-mail para cadastro. Em seguida, confirme o registro por meio do e-mail recebido e, após a verificação, faça “Login” na plataforma, que oferece acesso gratuito a 250 GB de armazenamento (com possibilidade de expansão).

- Carregando arquivos no Galaxy

Para carregar arquivos no Galaxy, localize o ícone **Upload** (📁) no painel lateral esquerdo e selecione **Choose local file** (📁). Por exemplo, carregue os arquivos **seq1.fasta** e **seq2.fasta** da pasta “roteiro1”. Em seguida, clique em **Start** e aguarde até que o upload atinja 100%. Por fim, verifique no painel direito **History** os arquivos aparecem em verde que indica que o processo foi concluído com sucesso.



Carregando arquivos no Galaxy desde o computador.



Roteiro 1

Algoritmos, Ferramentas e Pipelines

Introdução aos conceitos fundamentais para análises em Bioinformática

A lógica por trás das receitas digitais da bioinformática

Imagine que você está prestes a preparar um bolo especial. Ter os ingredientes certos, como farinha, ovos, leite e açúcar, não é suficiente: é preciso seguir uma sequência de preparo, isto é, uma receita, para obter o resultado desejado. Na bioinformática, podemos estabelecer uma analogia com a cozinha: os dados correspondem aos ingredientes, e o **algoritmo** à receita, que define o modo de preparo e organiza cada etapa.

Existem diferentes algoritmos, cada um com uma função específica, como comparar sequências, montar genomas ou classificar espécies. Cada algoritmo opera seguindo uma lógica interna de etapas, nas quais dados de entrada são processados para gerar uma saída específica. Quando conectamos esses algoritmos, de modo que a saída de um sirva como entrada para o próximo, formamos um **pipeline**, caracterizado por uma sequência linear de etapas. De forma mais geral, esse encadeamento pode ser descrito como um **work-flow**, que organiza o processamento, incluindo diferentes dependências entre etapas, e transforma dados brutos em informações biológicas interpretáveis.

Plataformas como o Galaxy tornam esse processo acessível ao permitir não apenas a execução de algoritmos individuais, mas também a organização desses fluxos de trabalho de forma estruturada e reproduzível.

Neste primeiro roteiro, você usará o Galaxy para explorar um dos algoritmos mais fundamentais da bioinformática: o Smith-Waterman, que realiza alinhamentos locais entre sequências, implementado na ferramenta water.

OBJETIVOS

- Compreender a diferença entre algoritmo, ferramenta, pipeline e workflow.
- Executar um alinhamento local (Smith-Waterman) no Galaxy e interpretar seus resultados.
- Construir e reutilizar um workflow no Galaxy, compreendendo o conceito de reprodutibilidade.

CONCEITOS PRÉVIOS

➤ O processo computacional

O processo computacional pode ser descrito, de forma geral, como uma sequência de etapas encadeadas, frequentemente organizado em: **Entrada**, **Processamento** e **Saída**. Na primeira etapa, **Entrada**, são fornecidos os dados que servirão como base para o processo. Esses dados podem ter diferentes naturezas e formatos.

Na segunda etapa, **Processamento**, são aplicadas operações definidas por algoritmos que transformam os dados de entrada. Essas operações podem ser ajustadas por meio de parâmetros, que controlam a forma como o algoritmo é executado.

Por fim, na etapa de **Saída**, são obtidos os resultados do processo, que correspondem aos dados transformados ou às informações derivadas a partir da entrada.




Figura 1: Etapas de um processo computacional

A descrição de um processo computacional pode ser feita em diferentes níveis de abstração. No nível conceitual, o **algoritmo** define os passos necessários para transformar dados de entrada em resultados, independentemente de como será implementado. Essa lógica pode ser representada de forma estruturada por meio de pseudocódigo, facilitando sua compreensão sem depender de uma linguagem de programação específica.

No nível de implementação, o algoritmo pode ser expresso em **código** (por exemplo, scripts em Python), permitindo sua execução por um computador. Um mesmo algoritmo pode ter diferentes implementações, dependendo da linguagem de programação ou da abordagem utilizada.

No nível de uso, uma **ferramenta computacional** disponibiliza essas implementações para uso prático, oferecendo interfaces e parâmetros que possibilitam a execução do processamento sem a necessidade de interação direta com o código.




Figura 2: Níveis de abstração no processo computacional.

➤ O processo computacional no Galaxy

Em bioinformática, o termo **pipeline** é utilizado para descrever processos computacionais organizados como uma sequência definida de etapas, na qual cada passo depende do anterior e o fluxo de execução é geralmente linear.

Por outro lado, o termo **workflow**, como utilizado em plataformas como o Galaxy, refere-se a uma representação formal e reutilizável de uma análise, composta por uma série de ferramentas e operações sobre dados executadas de forma automatizada, geralmente em sequência. Nesse contexto, os dados são organizados em **datasets**, que correspondem a arquivos ou conjuntos de dados processados pelas ferramentas, onde a saída de cada etapa serve como entrada da seguinte, favorecendo a reprodutibilidade e a reutilização do processo.

No Galaxy, embora os termos possam se sobrepor em alguns contextos, o termo workflow enfatiza a automação e a reutilização da análise, enquanto pipeline está mais associado a uma estrutura linear de execução.



Figura 3: Exemplo esquemático de um workflow no Galaxy.

➤ O Algoritmo smith-waterman

É um algoritmo clássico de programação dinâmica utilizado para realizar alinhamentos locais de sequências biológicas. Pode ser aplicado a sequências de DNA, RNA ou proteínas, com o objetivo de identificar regiões de maior similaridade entre duas sequências.

Durante o alinhamento, pares de posições entre as duas sequências são avaliados por meio de um sistema de pontuação: coincidências (**matches**) recebem valores positivos, enquanto diferenças (**mismatches**) e lacunas (**gaps**) são penalizadas.

Com base nesse sistema de pontuação, o algoritmo constrói uma matriz, na qual cada posição representa a melhor pontuação possível para um alinhamento local até essa posição. A partir dessa matriz, é possível identificar o alinhamento local com a maior pontuação.

Exemplo: Considere o seguinte alinhamento obtido pelo algoritmo de Smith–Waterman:

```
Sequência_1: CTCT--CTGATAAG
              |||. |. ||. |||
Sequência_2: CTCCTGCCGACAAG
```

Os símbolos utilizados no alinhamento são: **|**, que indica um **match**; **.**, que indica um **mismatch**; e **-**, que indica um **gap**.

GUIA PASSO A PASSO

1. A lógica de um algoritmo e sua implementação

Nesta primeira etapa, você irá explorar o processo computacional de alinhamento de sequências. O foco será compreender como esse processo se organiza em termos de entrada, processamento e saída, sendo que o algoritmo **smith-waterman** é tomado como base na etapa de processamento.

Inicialmente, os passos do algoritmo serão representados em pseudocódigo, proporcionando uma visão mais estruturada de seu funcionamento. Em seguida, será apresentada sua implementação em Python, para observar como a lógica do algoritmo é implementada em código.

- a) Leia atentamente as etapas do processo computacional para alinhamento de sequências. Em seguida, foque na etapa de processamento, que apresenta os passos do algoritmo smith-waterman.

ENTRADA

1. Definir as duas sequências de entrada
2. Definir o sistema de pontuação

PROCESSAMENTO

3. Construir a matriz de pontuação com dimensões baseadas nas sequências de entrada
4. Inicializar a matriz com valores das penalidades de gap
5. Preencher a matriz considerando as transições diagonal, superior e lateral, aplicando o critério de máximo.
6. Identificar o maior valor em toda a matriz
7. Realizar o traceback a partir do maior valor encontrado, até atingir uma célula com valor zero

SAÍDA

8. Mostrar o alinhamento local reconstruído

O **traceback** é o processo de percorrer a matriz no sentido inverso para identificar como o alinhamento foi construído. A partir da última célula, segue-se o caminho de maior pontuação até o início, reconstruindo o alinhamento passo a passo.

- b) Observe agora a representação do algoritmo smith-waterman em pseudocódigo.

Algorithm 1: Algoritmo smith-waterman para alinhamento local

Entrada: Sequências seq1 e seq2;

Parâmetros de pontuação (match, mismatch, gap)

Saída : Alinhamento local

```
1 rows ← tamanho de seq2 + 1
2 cols ← tamanho de seq1 + 1
3 matrix ← matriz de tamanho rows × cols
4 Inicializar a primeira linha e a primeira coluna de matrix com penalidades de gap;
5 Para cada linha i, de 1 até rows - 1 faça
6   Para cada coluna j, de 1 até cols - 1 faça
7     diagonal ← matrix[i - 1][j - 1] + (match se seq2[i - 1] =
8       seq1[j - 1]; caso contrário mismatch)
9     cima ← matrix[i - 1][j] + gap
10    esquerda ← matrix[i][j - 1] + gap
11    matrix[i][j] ← max(diagonal, cima, esquerda)
12 fim
13 Iniciar na célula com o maior valor de toda a matriz
14 Enquanto não chegar à célula inicial faça
15   identificar a direção (diagonal, cima ou esquerda) que gerou o valor da célula
16   atualizar o alinhamento adicionando caracteres correspondentes ou gaps
17 fim
18 Mostrar o alinhamento local reconstruído
```

Um **pseudocódigo** é uma forma estruturada de descrever a lógica de um algoritmo, utilizando uma linguagem próxima à programação, mas voltada à compreensão humana e independente de uma linguagem específica.

1.b - Complete a correspondência entre os passos do algoritmo smith-waterman na etapa processamento e as linhas do pseudocódigo. Em seguida, justifique cada associação explicando por que essas linhas representam aquele passo, com base na lógica do algoritmo.

Smith-Waterman	Pseudocódigo	Justificativa
3. Construir matriz	1-3	...
4. Inicializar matriz		
5. Preencher matriz		
7. Realizar traceback		

c) Acesse o link abaixo e analise o script que implementa o algoritmo:

smith-waterman-algorithm.py

Um script é um arquivo que contém instruções escritas em uma linguagem de programação, seguindo uma sintaxe específica que permite sua execução por um computador.

- d) No script, localize as linhas que começam com o caractere “#”, que indicam comentários no código, e observe as explicações associadas.

As linhas iniciadas por “#” são chamadas de comentários. Elas não são executadas pelo programa, mas ajudam a explicar o que o código faz, sendo úteis para a leitura e compreensão por outras pessoas.

- e) Localize no script o bloco de código correspondente às linhas 37 a 41:

```
37 def smith_waterman(seq1, seq2):
38     # Generating the empty matrices for storing scores and ...
39     row = len(seq1) + 1
40     col = len(seq2) + 1
41     matrix = np.zeros(shape=(row, col), dtype=np.int)
```

Uma função em Python é um bloco de código que realiza uma tarefa específica e pode ser reutilizado várias vezes dentro de um programa. A definição de uma função segue o formato:

```
def funcao(param1, param2)
```

Os parênteses podem conter parâmetros, como `param1`, `param2`. Eles representam os valores de entrada da função utilizados durante sua execução.

1.e - Na função `smith_waterman`. O que representam os parâmetros `seq1` e `seq2`, e as variáveis `row` e `col`? Qual funcionalidade do algoritmo corresponde às linhas 39–41? Justifique sua resposta.

- f) Agora, observe o bloco de código das linhas 49 a 59, responsável pelo preenchimento da matriz de pontuação no algoritmo de smith-waterman:

```
49 for i in range(1, row):
50     for j in range(1, col):
51         # Calculating the diagonal score (match score)
52         match_value = Score.MATCH # ...
53         diagonal_score = matrix[i - 1, j - 1] + match_value
54
55         # Calculating the vertical gap score
56         vertical_score = matrix[i - 1, j] + Score.GAP
57
58         # Calculating the horizontal gap score
59         horizontal_score = matrix[i, j - 1] + Score.GAP
```

1.f - Observe o uso de duas instruções “for” nas linhas de código e as três variáveis `diagonal_score`, `vertical_score` e `horizontal_score`. O que isso indica sobre a forma como a matriz é percorrida e preenchida? Por que essa abordagem é necessária para o algoritmo? Justifique.

2. Explorar ferramentas prontas para uso

Nesta etapa, você irá explorar como algoritmos são utilizados na prática por meio de ferramentas computacionais. O algoritmo **smith-waterman**, estudado na etapa anterior, será aplicado com a ferramenta **water**, disponível na plataforma Galaxy

- a) Faça login na plataforma Galaxy com seu usuário cadastrado.

Caso ainda não tenha criado sua conta, siga as instruções para cadastro descritas na seção Primeiros Passos.

- b) Utilize a ferramenta `Download-directory.github` para baixar a pasta `roteiro1`, como indicado na seção Primeiros Passos.
- c) Carregue os arquivos `seq1.fasta` e `seq2.fasta` a partir da pasta `roteiro1` usando o ícone Upload () como indicado na seção Primeiros Passos.
- d) Procure a ferramenta **water** usando o ícone **Tools** (). Na sequência, configure os parâmetros conforme indicado a seguir:

Sequence 1: seq1.fasta
Sequence 2: seq2.fasta
Gap open penalty: 10.0
Gap extension penalty: 0.5
Output alignment file format: SRS pair (m)
▶ **Run Tool:**

- e) O resultado da análise anterior aparecerá no painel History, em um arquivo cujo nome estará relacionado à análise realizada. Aguarde a execução das análises, pendente em History, e depois renomeie o arquivo para `smith_default.txt` usando o ícone **Edit Attributes** () e salve as alterações usando o ícone **Save** ()

No Galaxy, todos os arquivos utilizados e gerados em uma análise são registrados no painel History. Cada arquivo recebe uma identificação automática, mas seus nomes podem ser ajustados para facilitar a organização dos resultados.

- f) Visualize os resultados gerados clicando no ícone View ()

2.f - Qual foi o resultado obtido (número de colunas no alinhamento, score e parâmetros)? Faça um print da tela desse resultado. O que esses valores indicam sobre a similaridade entre as sequências? Justifique.

- g) Execute novamente **water**, mas agora considerando os seguintes parâmetros::

Sequence 1: seq1.fasta
Sequence 2: seq2.fasta
Gap open penalty: 2
Gap extension penalty: 1
Output alignment file format: SRS pair (m)
▶ **Run Tool:**


- h) Renomeie o arquivo gerado para `smith_open2exten1.txt` e salve as alterações, conforme descrito em (e). Observe os novos resultados, conforme descrito em (f)

2.h - Como a mudança dos parâmetros alterou o resultado do alinhamento? Faça um print da tela desse resultado. O que você observa em termos de *matches*, *mismatches* e *gaps*? Como essas diferenças impactam a interpretação biológica? Justifique.

- i) (Opcional) Tente reproduzir os resultados usando a ferramenta iterativa Global Alignment App e usando as mesmas sequências.

3. Execução sequencial de ferramentas e construção de um workflow

Nesta etapa, você executará diferentes ferramentas de forma sequencial no Galaxy, simulando um fluxo de análise. O objetivo é mostrar como essas etapas podem ser integradas em um processo reprodutível, que posteriormente será exportado como um workflow. As ferramentas utilizadas e sua ordem de execução são apresentadas a seguir:



- a) Carregue e visualize o arquivo **seqs_trxA.fasta** no painel History. Clique no ícone *View* e, em seguida, na seção *Details*. Observe como o arquivo carregado é identificado no Galaxy.

No Galaxy, **Datasets** (■) correspondem aos dados de entrada e saída de cada etapa de uma análise. Isso significa que todo arquivo carregado ou gerado por uma ferramenta é considerado um dataset, podendo ser reutilizado em etapas seguintes do fluxo de análise.

- b) A primeira ferramenta a ser utilizada é o **SeqKit statistics**, que obtém estatísticas de um arquivo FASTA. Procure a ferramenta e configure seus parâmetros conforme indicado a seguir.

Input file: seqs_trxA.fasta
Output all statistics: No
Output base name of input file: No
▶ **Run Tool:**

3.b - Observe o arquivo gerado. Qual é o seu formato e que tipo de sequências ele contém? O que as características observadas indicam sobre os dados analisados? Justifique.

- c) A segunda ferramenta é o **transeq**, que realiza a tradução das sequências de nucleotídeos em aminoácidos. Procure a ferramenta e configure seus parâmetros conforme indicado abaixo. Em seguida, renomeie o dataset gerado para “**trxA_prt.fasta**” e salve as alterações.

Sequences: seqs_trxA.fasta
Frame(s) to translate: Frame 1
Code to use: Bacteria
Output sequence file formate: FASTA (m)
▶ **Run Tool:**

- d) A terceira ferramenta é o **pepstats**, que calcula estatísticas básicas de sequências proteicas. Procure a ferramenta e configure seus parâmetros conforme indicado abaixo. Em seguida, renomeie o arquivo gerado para “**trxA_prt_pepstats.txt**” e salve as alterações.

Sequences: trxA_prt.fasta
Include charge at N and C terminus: No
▶ **Run Tool:**

3.d - Quais são as propriedades obtidas das sequências (resíduos, peso molecular, carga e ponto isoelétrico)? O que essas propriedades sugerem sobre as características das sequências? Justifique.

- e) A quarta ferramenta é o **Split Fasta**, que separa as sequências em arquivos FASTA individuais. Procure a ferramenta e configure seus parâmetros conforme indicado a seguir.

Sequences: trxA_prt.fasta
Split mode: Each sequence in its own dataset
▶ **Run Tool:**

- f) O resultado da etapa anterior gera uma *collection*, que agrupa vários *datasets*, cada um correspondendo a uma sequência no formato FASTA. Observe que esses *datasets* recebem como nome o ID da sequência e mantêm o formato original.

No Galaxy, uma **collection** agrupa vários datasets em um único objeto, permitindo que ferramentas sejam aplicadas a todos eles de forma conjunta, o que torna a análise mais rápida e organizada.

- g) Por fim, a última ferramenta a ser utilizada é o **water**, que utilizará os *datasets* gerados na etapa anterior. Procure a ferramenta e configure seus parâmetros conforme indicado abaixo. Para acessar os *datasets*, é necessário clicar no ícone *Browse or Upload Datasets* (••) e, em seguida, localizar a coleção de *datasets*, representada como uma pasta.

Sequence 1: Split Fasta on dataset Sent_trxA_1

Sequence 2: Split Fasta on dataset Ecol_trxA_1

Output alignment file format: FASTA (m)

▶ **Run Tool:**

3.g - Qual foi o resultado obtido desta vez? Descreva-o. O que muda em relação ao formato anterior gerado pela ferramenta water? Em que situações esse formato é mais adequado? Justifique.

- h) Agora vamos exportar o workflow. No painel History, localize o ícone **History options** () , clique nele e selecione **Extract Workflow**. Na janela que será aberta, atribua um nome ao workflow.

Observe que são exibidas duas colunas: uma com as ferramentas utilizadas e outra com os itens do History (*datasets* e *collections*). Selecione apenas os itens a partir de **seqs_trxA.fasta**; isso implica desmarcar os demais. Em seguida, clique em **Create Workflow**.

- i) Para visualizar o workflow criado, localize o ícone **Workflows** () no painel da direita, clique na aba *My workflows* e, na lista exibida, localize seu workflow. Em seguida, clique nele para visualizá-lo.
- j) (Opcional) Navegue pelos repositórios do Github de **Snakemake** e **Nextflow**, alternativas robustas para a construção e execução de pipelines bioinformáticos que, no entanto, exigem maior familiaridade com linha de comando, programação e organização de ambientes computacionais. Explore a documentação disponível nos repositórios oficiais:

- <https://github.com/snakemake/snakemake>
- <https://github.com/nextflow-io/nextflow>

Diferentemente do Galaxy, essas ferramentas são voltadas principalmente para execução em ambientes locais ou de computação de alto desempenho (HPC) e são amplamente utilizadas em projetos de pesquisa que exigem maior flexibilidade e escalabilidade.

4. Navegar pelos workflows do Galaxy e outras funcionalidades

Como visto na etapa anterior, o Galaxy permite criar, executar e exportar workflows. Além disso, a plataforma disponibiliza workflows públicos, desenvolvidos e compartilhados pela comunidade. Nesta etapa, o objetivo é explorar esses workflows.

- a) Localize o ícone **Workflows** no painel da direita. Explore as abas *Workflows shared with me* e *Public Workflows*.
- b) Na aba *Public Workflows*, você encontrará workflows para diferentes aplicações. Utilize o campo de busca para procurar workflows voltados à montagem de genomas bacterianos, considerando os seguintes critérios:

Search: Bacterial Genome Assembly

Sort by: Update time

Sort by: Name

4.b - Após realizar a busca conforme as instruções, escolha um workflow recente (preferencialmente na versão mais atual) e analise-o. Faça um print do workflow selecionado. Como ele está organizado (entrada, etapas e saída)? O que essa organização revela sobre o processo de análise? Justifique sua resposta.

- c) Outros recursos de visualização oferecidos pelo Galaxy podem ser acessados por meio de **Visualization** () . Para explorar essa funcionalidade aplicada ao alinhamento de sequências, clique em *Visualization* e procure a ferramenta **Multiple Sequence Alignment and Sequence Logo**. Em seguida, configure seus parâmetros conforme indicado a seguir:

Select to Visualize: trxA_prt.aln

4.c - Qual ferramenta de visualização você escolheu? Que tipo de informações o visualizador apresenta? Como essas informações contribuem para a interpretação dos dados analisados? Justifique sua resposta.

- d) Para complementar seus estudos, saiba que além de *Visualization*, o Galaxy também oferece a interação com outros ambientes computacionais por meio de **Interactive Tools** () . As ferramentas disponibilizadas no *Interactive Tools* permitem o uso de terminais, notebooks, entre outros, úteis para análises exploratórias, visualizações dinâmicas e execução de código personalizado.


O **Iterative JupyterLab Notebook** é uma das opções mais utilizadas para execução de código no Galaxy. Ele permite executar scripts diretamente nesse ambiente, como aquele apresentado na etapa 1. Dessa forma, é possível implementar um algoritmo e executá-lo no próprio Galaxy, sem a necessidade de ferramentas externas.

RELATÓRIO FINAL

Elabore um relatório com base nas respostas, organizando-as de forma clara, com análise e interpretação dos resultados.

REFERÊNCIAS

Afgan, E., Baker, D., Coraor, N. et al. Galaxy CloudMan: delivering cloud compute clusters. *BMC Bioinformatics*, 2010.



Roteiro 2

Comparação de Sequências Biológicas

Busca de sequências semelhantes e identificação de homólogos

Como descobrir a função de uma proteína desconhecida?

Imagine que você encontra uma frase misteriosa escrita em uma língua antiga que você não conhece. Um primeiro passo natural seria buscar padrões ou trechos semelhantes em textos já catalogados, na tentativa de obter pistas sobre seu significado. Na bioinformática, seguimos uma lógica parecida. Quando buscamos compreender a função de uma proteína ainda desconhecida, **comparamos** sua sequência com milhões de outras já anotadas em bancos de dados públicos, procurando similaridades que possam indicar **relações funcionais ou evolutivas**.

Ferramentas como o BLAST funcionam como um “Google das sequências biológicas”, permitindo identificar sequências semelhantes a uma sequência desconhecida e reconhecer seus “parentes” mais próximos. A partir dessas **semelhanças**, é possível levantar hipóteses sobre sua função, se ela atua no metabolismo básico da célula, se está associada à resistência a antibióticos, ou se tem papel na virulência de um patógeno, por exemplo.

Neste roteiro, você irá trabalhar com sequências de proteínas e nucleotídeos de função desconhecida, utilizando o BLAST do NCBI e a plataforma Galaxy para realizar buscas de similaridade. A partir dos resultados obtidos, você aprenderá a interpretar as métricas geradas e a sustentar hipóteses funcionais com base em evidências estatísticas e biológicas.

OBJETIVOS

- Executar buscas de similaridade utilizando BLASTp em bases de dados públicas e personalizadas.
- Interpretar as métricas geradas pelo BLAST, incluindo E-value, porcentagem de identidade e cobertura.
- Avaliar o impacto da modificação de parâmetros do BLAST nos resultados obtidos.
- Integrar evidências de similaridade para propor hipóteses sobre a função de proteínas desconhecidas.

CONCEITOS PRÉVIOS

➤ Inferência de homologia e de função

A homologia refere-se à relação evolutiva entre sequências que descendem de um ancestral comum. Como essa relação não pode ser observada diretamente, ela é inferida a partir de evidências de similaridade, o grau de correspondência observado entre duas sequências, considerando coincidências exatas, substituições conservativas e padrões conservados que preservam propriedades biológicas.

Um caso particular de similaridade é a identidade, que corresponde à porcentagem de posições onde os caracteres são exatamente iguais entre duas sequências. Embora seja uma medida intuitiva, a identidade sozinha não é suficiente para avaliar a relevância biológica de um alinhamento. Para isso, utilizam-se métricas complementares: o Score, que reflete a qualidade geral do alinhamento considerando correspondências, substituições e gaps; e o E-value, que estima a probabilidade de se encontrar um alinhamento de qualidade igual ou superior ao acaso. Quanto menor o E-value, maior a significância estatística do alinhamento.

Quando a similaridade observada é estatisticamente significativa, a homologia pode ser inferida como hipótese plausível. A partir dessa relação, é possível também propor hipóteses sobre a função da sequência analisada, partindo do pressuposto de que sequências evolutivamente relacionadas tendem a conservar estrutura e função. No entanto, essa inferência deve ser feita com cautela, proteínas homólogas podem ter adquirido funções distintas ao longo da evolução, o que exige que as hipóteses funcionais sejam sempre sustentadas por múltiplas evidências.

➤ Basic Local Alignment Search Tool (BLAST)

O BLAST é um conjunto de ferramentas computacionais que realiza buscas por similaridade entre sequências biológicas. Seu princípio básico consiste em identificar regiões de correspondência local entre uma sequência de consulta (**Query**) e um conjunto de sequências em uma base de dados (**Subjects**), retornando os alinhamentos mais significativos acompanhados de métricas estatísticas.

O BLAST possui diferentes programas que se diferenciam pelo tipo de sequência analisada, DNA ou proteína, e pelo uso direto das sequências ou de sua tradução prévia. As principais variantes estão resumidas na Tabela 1.

Tabela 1: Principais programas do BLAST e os tipos de sequências comparadas.

Programa	O que compara
BLASTn	DNA vs DNA
BLASTp	proteína vs proteína
BLASTx	DNA (traduzido) vs proteína
tBLASTn	proteína vs DNA (traduzido)
tBLASTx	DNA (traduzido) vs DNA (traduzido)

O processo de busca da ferramenta começa com a definição da sequência query, que é

comparada contra a base de dados contendo as sequências subjects. Como resultado, o BLAST retorna os alinhamentos mais significativos, denominados hits, acompanhados de métricas como porcentagem de identidade, Score e E-value, que permitem avaliar as relações evolutivas e propor hipóteses funcionais. Neste roteiro, será utilizado principalmente o BLASTp, que compara sequências de proteínas, conforme ilustrado na Figura 4.




Figura 4: Fluxo geral do BLAST para comparação de sequências utilizando BLASTp

GUIA PASSO A PASSO

1. Comparar duas sequências usando BLAST

Nesta etapa, você utilizará o **blastp**, programa da ferramenta BLAST disponível no portal do NCBI, para comparar diretamente duas sequências de proteínas e interpretar suas principais métricas. Entre elas destacam-se: a **Identidade**, que indica a porcentagem de posições idênticas na região alinhada, o **Score**, que reflete a qualidade do alinhamento, e o **E-value**, que representa a significância estatística do resultado. Trabalhar com apenas duas sequências permite familiarizar-se com essas métricas de forma mais direta antes de explorar a busca em bases de dados nas etapas seguintes.

- a) Utilize a ferramenta [Download-directory.github](https://github.com/Download-directory) para baixar a pasta **roteiro2**, como indicado na seção Primeiros Passos.
- b) Acesse ao site do BLAST-NCBI ([blast.ncbi](https://blast.ncbi.nlm.nih.gov/)) e selecione o programa *Protein BLAST* (*protein > protein*).

BLAST possui diferentes programas que se diferenciam pelo tipo de sequências comparadas (query e subject). No **blastp**, tanto o query quanto o subject são sequências de proteínas.

- c) Habilite a opção *Align two or more sequences* no **blastp** e configure os parâmetros conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence1.fasta
Job Title: Meu blastp de 2 Sequências
Enter Subject Sequence: Choose File > sequence2.fasta
BLAST:

Caso a tabela de resultados apresente sobreposição, utilize a opção *Select columns* e ajuste as colunas *Cluster Composition* e *Cluster Ancestor*. Isso, trata-se apenas de um ajuste para melhorar a visualização.

- d) Agora, examine a tabela de resultados apresentada na aba padrão, identificando as principais estatísticas da análise. Esse passo tem como objetivo familiarizar-se com as métricas de Identidade, Score e E-value.
- e) Na aba *Graphic Summary*, visualize a representação gráfica da comparação entre as sequências. As cores utilizadas refletem o Score do alinhamento, indicando a qualidade da correspondência em cada região.
- f) Na aba *Alignments*, visualize os alinhamentos correspondentes ao resultado obtido. Esses alinhamentos mostram como as sequências se alinham posição por posição, permitindo identificar correspondências, diferenças e gaps.

Alinhamentos mais longos e contínuos com menos gaps tendem a apresentar maior Score e menor E-value, enquanto alinhamentos com mais gaps e menor comprimento resultam em scores mais baixos e E-values mais elevados.

1.f - Faça um screenshot dos resultados obtidos em d) e f). Com base na tabela de resultados em d), identifique os valores de Identidade, Score e E-value e relacione-os com o alinhamento correspondente observado em f). Qual alinhamento apresenta melhor qualidade? Justifique sua resposta com base nas características observadas, como continuidade, presença de gaps e número de posições idênticas.

- g) Por fim, na aba *Dot Plot*, visualize a representação gráfica da similaridade entre as sequências. Nesse gráfico, o eixo x corresponde à sequência query, o eixo y à sequência subject, e os pontos indicam regiões de correspondência entre elas.

1.g - Faça um screenshot do Dot Plot obtido. Com base no padrão observado, que tipo de relação entre as sequências ele sugere? Relacione esse padrão com os alinhamentos identificados em f).

2. Busca de sequencias usando bases de dados públicas

Nesta etapa, você utilizará o **blastp** para comparar uma sequência de consulta (query) contra uma base de dados pública, obtendo múltiplas sequências-alvo denominadas hits. Além das métricas já vistas, será introduzido o **Query cover**, que indica a proporção da sequência de consulta envolvida em cada alinhamento. Com base nessas métricas, você deverá avaliar a qualidade dos hits e inferir a função da sequência analisada.

- a) Acesse ao site do BLAST-NCBI (blast.ncbi.nlm.nih.gov) e clique em *Protein BLAST* (*protein > protein*). Em seguida, no **blastp**, utilize o arquivo **sequence1.fasta** da pasta **roteiro2** e configure os parâmetros conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence1.fasta
Choose Search Set/Database: Non-redundant protein sequences (nr)
BLAST:

A base de dados *nr* (non-redundant) do NCBI integra sequências provenientes de múltiplas bases de dados. Trata-se de uma base ampla, na qual muitas anotações são geradas automaticamente.

- b) Em uma nova aba, execute novamente o *Protein BLAST* com a mesma sequência de consulta, desta vez utilizando uma base de dados diferente, para comparar com o resultado anterior. Configure os parâmetros conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence1.fasta
Choose Search Set/Database: UniProtKB/Swiss-Prot (swissprot)
BLAST:

A base de dados UniProtKB/Swiss-Prot é menor e menos redundante do que a base de dados *nr*. Sua principal vantagem é a curadoria manual, na qual as sequências são revisadas por especialistas. Isso resulta em anotações funcionais mais confiáveis.

- c) Navegue pelas abas *Description*, *Graphic Summary* e *Alignments* em ambos os resultados, familiarizando-se com as métricas de identidade, E-value e query cover, bem como com a representação dos alinhamentos. Examine também a aba *Taxonomy*, que apresenta a distribuição taxonômica das sequências encontradas.

2.c - Faça um screenshot da aba *Description* de ambos os resultados. Com base nos hits obtidos, as duas bases de dados sugerem a mesma função para a sequência query? A qual família proteica ela poderia pertencer? Justifique sua resposta utilizando os valores de identidade, E-value e Query cover observados.

- d) Acesse novamente o *Protein BLAST*. Utilize o arquivo `queries.fasta` da pasta `roteiro2`, que contém múltiplas sequências de consulta, permitindo obter os resultados de todas em uma única execução. Configure os parâmetros conforme indicado a seguir:

Enter Query Sequence: Choose File > queries.fasta
Choose Search Set/Database: UniProtKB/Swiss-Prot (swissprot)
BLAST:

Após a execução, visualize os resultados obtidos. Na seção *Results for*, identifique a lista das sequências de consulta analisadas e selecione cada uma delas para acessar os resultados correspondentes. Em seguida, selecione a primeira sequência e explore as abas *Description*, *Graphic Summary* e *Alignments*.

2.d - Faça um screenshot da aba *Description* e do alinhamento obtidos. Com base nas métricas de identidade, E-value e Query cover, qual seria a função provável desta sequência? As métricas obtidas são suficientes para sustentar essa inferência? Justifique sua resposta.

- e) Clique no segundo resultado da mesma busca e visualize as abas *Description*, *Graphic Summary* e *Alignments*.

A interpretação dos resultados deve considerar as métricas de forma integrada. Alinhamentos com menor identidade podem ser relevantes se apresentarem bom Query cover e baixo E-value, enquanto alta identidade com baixo Query cover pode refletir correspondências restritas a regiões curtas.

2.e - Faça um screenshot da aba *Description* e do alinhamento obtidos. Considerando que esta sequência apresenta baixa identidade, ainda seria possível inferir sua função? Justifique sua resposta analisando conjuntamente os valores de identidade, Query cover e E-value observados.

- f) Clique no terceiro resultado da mesma busca e visualize as abas *Description*, *Graphic Summary* e *Alignments*.

2.f - Faça um screenshot da aba *Description* e do alinhamento obtidos. Considerando os valores de identidade, Query cover e E-value observados, seria possível inferir com confiança a função desta sequência? O que a relação entre o tamanho da sequência e a extensão da região alinhada indica sobre a qualidade desse resultado? Justifique sua resposta.

- g) Clique no quarto resultado da mesma busca e visualize as abas *Description*, *Graphic Summary* e *Alignments*.

Nem sempre o BLAST identifica sequências homólogas. Quando não há sequências semelhantes na base de dados, nenhum Hit significativo é retornado, o que impede a inferência funcional direta. Nesses casos, uma alternativa é buscar domínios conservados na sequência, que podem fornecer pistas sobre sua função mesmo na ausência de homólogos conhecidos — como explorado no item opcional a seguir.

- h) (Opcional) Copie a sequência para a qual não foram encontrados hits significativos e utilize o site *InterPro* para identificar possíveis domínios proteicos. O que os domínios encontrados sugerem sobre a função desta sequência?

3. Análise do efeito da modificação de parâmetros no BLAST

Nesta etapa, você utilizará o programa **blastn** para explorar como a modificação de parâmetros, por meio da opção **Algorithm parameters**, afeta os resultados da busca. Ao alterar esses parâmetros, você deverá observar e analisar as mudanças nos Hits recuperados, bem como nos valores de Score e E-value, refletindo sobre como essas variações influenciam a interpretação dos resultados.

- a) Acesse o site do BLAST-NCBI ([blast.ncbi](http://blast.ncbi.nlm.nih.gov)) e selecione *Nucleotide BLAST (nucleotide > nucleotide)*. Em seguida, clique em *+Algorithm parameters* para visualizar e familiarizar-se com os parâmetros padrão utilizados pelo **BLASTn**.

Esta configuração será considerada o **padrão de comparação**, servindo como referência para avaliar os efeitos da modificação dos parâmetros nas análises seguintes.

- b) Ative a opção *Show results in a new window* para que os resultados sejam abertos em uma nova aba, mantendo a janela principal disponível para os experimentos seguintes. Em seguida, utilize o arquivo **sequence7.fasta** da pasta **roteiro2** e configure os parâmetros conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence7.fasta
Choose Search Set/Database: Reference RNA sequences (refseq_rna)
Program Selection: Somewhat similar sequences (blastn)
BLAST: Show results in a new window

3.b - Quais são os parâmetros e valores padrão exibidos em *+Algorithm parameters*? Utilizando essa configuração, qual é a possível função da sequência analisada? Justifique sua resposta com base nas estatísticas apresentadas nos resultados.

- c) Registre, na tabela a seguir, os resultados obtidos com a configuração padrão (controle). Essa tabela será utilizada para acompanhar e comparar como os valores de número de Hits, Score, Query cover, Identidade e E-value variam em função das modificações dos parâmetros nas análises seguintes.

Análise	Parâmetro	Total of Hits	Max Score	Query Cover	Per. Ident	E value
Controle	default					
2ª análise	Word size 7					
3ª análise	Word size 15					
4ª análise	Match/Mismatch 1/-1					
5ª análise	Database Teleopsis					

- d) Retorne à janela principal e realize a **segunda análises** com **BLASTn**, modificando apenas o parâmetro *Word size* em relação à configuração controle, conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence7.fasta
Choose Search Set/Database: Reference RNA sequences (refseq_rna)
Program Selection: Somewhat similar sequences (blastn)
Word size: 15
BLAST: Show results in a new window

O *Word size* define o tamanho mínimo da correspondência inicial entre as sequências antes de estender o alinhamento.

- e) Retorne à janela principal e realize a **terceira análises** com **BLASTn**, modificando novamente o parâmetro *Word size*, desta vez para um valor menor conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence7.fasta
Choose Search Set/Database: Reference RNA sequences (refseq_rna)
Program Selection: Somewhat similar sequences (blastn)
Max target sequences: 250
Word size: 7
BLAST: Show results in a new window

Repare que a alteração de *Max target sequences* afeta apenas o número de resultados exibidos, sem interferir no processo de busca do **BLASTn**.

- f) Retorne à janela principal e realize a **quarta análises** com **BLASTn**, modificando o parâmetro *Match/Mismatch Scores* em relação à configuração controle.

Enter Query Sequence: Choose File > sequence7.fasta
Choose Search Set/Database: Reference RNA sequences (refseq_rna)
Program Selection: Somewhat similar sequences (blastn)
Match/Mismatch Scores: 1,-1
BLAST: Show results in a new window

O parâmetro *Match/Mismatch Scores* define a recompensa atribuída a posições idênticas e a penalização por substituições no alinhamento.

- g) Retorne à janela principal e realize a **quinta análise** com **BLASTn**, restringindo a busca a um organismo específico. Configure os parâmetros conforme indicado a seguir:

Enter Query Sequence: Choose File > sequence7.fasta
Choose Search Set/Database: Reference RNA sequences (refseq_rna)
Choose Search Set/Organism: Teleopsis (taxid:139679)
Program Selection: Somewhat similar sequences (blastn)
BLAST: Show results in a new window

A restrição da busca a um organismo atua como um filtro, limitando as sequências consideradas na base de dados. Isso reduz o tamanho efetivo da base pesquisada e afeta o E-value, uma vez que essa métrica depende diretamente do número de sequências avaliadas.

- h) Por fim, preencha toda a tabela com os valores obtidos em cada análise, de modo a comparar os efeitos das modificações realizadas nos parâmetros.

3.h - Com base nos resultados da tabela, qual parâmetro gerou as mudanças mais significativas nos resultados do BLASTn? Justifique sua resposta comparando os valores das colunas *Total of Hits*, *Max Score*, *Query Cover*, *Per. Ident* e *E-value* entre o controle e as demais análises. O que isso indica sobre o impacto desse parâmetro em relação aos demais?

- i) (Opcional) Utilizando a sequência inicial na Etapa 2, construa uma tabela semelhante à utilizada nesta etapa. Desta vez, substitua o experimento de *Match/Mismatch* pela alteração da matriz de substituição, comparando a matriz padrão com uma alternativa, como *PAM30* ou *BLOSUM45*. Avalie como essa mudança afeta os resultados obtidos.

4. Busca de sequências usando bases de dados personalizadas

Até agora, você utilizou bases de dados públicas, que são adequadas para a maioria das buscas. No entanto, em algumas situações é necessário restringir a busca a um conjunto específico de sequências, o que exige a criação de uma base de dados personalizada. Nesta etapa, você aprenderá a construir essa base a partir de um arquivo FASTA utilizando a ferramenta **makeblastdb** do NCBI BLAST+, disponível na plataforma Galaxy, e a utilizá-la como alvo de busca com o programa **blastp**.

- a) Faça login na plataforma Galaxy com seu usuário cadastrado.

Caso ainda não tenha criado sua conta, siga as instruções de cadastro descritas na seção Primeiros Passos.

- b) Carregue os arquivos `sequence1.fasta` e `database.fasta` a partir da pasta `roteiro2`, usando o ícone Upload (📁), conforme indicado na seção Primeiros Passos. Isso disponibilizará tanto a sequência de consulta quanto o conjunto de sequências que será utilizado para construir a base de dados personalizada.

Após carregar os arquivos, visualize o conteúdo do arquivo `database.fasta` clicando no ícone de visualização (.

- c) Observe que as sequências presentes nesse arquivo correspondem a proteínas relacionadas a família RecA e possuem estrutura tridimensional resolvida no PDB (Protein Data Bank), evidenciando que se trata de um conjunto previamente caracterizado.

O PDB é uma base de dados de estruturas tridimensionais de proteínas. Isso significa que todas as sequências presentes nesse arquivo possuem estrutura experimental resolvida e depositada nessa base.

- d) Para construir uma base de dados BLAST a partir do arquivo `database.fasta`, busque a ferramenta **NCBI BLAST+ makeblastdb** utilizando o ícone **Tools** () e configure os parâmetros conforme indicado a seguir:

Molecule type of input: protein
*1: Select input/FASTA input *:* database.fasta
Run:

- e) Ao término da execução, clique no nome do output gerado e observe que o resultado não é mais um arquivo FASTA, mas um conjunto de arquivos que compõem a base de dados no formato BLAST.

O resultado corresponde a uma base de dados no formato BLAST, gerada a partir do arquivo FASTA. Essa base é composta por arquivos indexados que permitem a execução de buscas eficientes com ferramentas BLAST.

- f) Renomeie a base de dados gerada para `minha_database`. Para isso, clique no ícone **Edit Attributes** () e salve as alterações clicando no ícone **Save** (). Essa base de dados será utilizada como entrada no BLASTP na próxima análise.
- g) Procure pela ferramenta **NCBI BLAST+ blastp** e configure os parâmetros conforme indicado a seguir:

*Protein query sequence(s) *:* sequence1.fasta
Subject database/sequences: BLAST database from your history
*Protein BLAST database *:* minha_database
Output format: Tabular (Pairwise text)
Run:

Clique no ícone de visualização () para visualizar o output gerado e familiarize-se com as informações apresentadas.

- h) Execute novamente a busca com **BLASTP**, desta vez utilizando a base de dados personalizada criada e selecionando o formato de saída tabular, que permite visualizar e comparar de forma estruturada as principais métricas dos alinhamentos:

Protein query sequence(s) *: sequence1.fasta
Subject database/sequences: BLAST database from your history
Protein BLAST database *: minha_database
Output format: Tabular (standard 12 columns)
Run:

- i) Clique no ícone de visualização () para examinar o output tabular gerado e reconheça as colunas que descrevem as métricas do alinhamento.

No formato tabular padrão (12 colunas), cada coluna representa uma métrica do alinhamento, incluindo: identificadores da sequência query e do subject, porcentagem de identidade, comprimento do alinhamento, mismatches, gaps, posições inicial e final no query e no subject, E-value e score. Essas métricas já foram utilizadas nas etapas anteriores, mas aqui são apresentadas de forma estruturada em tabela, facilitando a comparação entre múltiplos resultados.

4.i.1 - Faça um screenshot do resultado tabular obtido em h). Com base nos valores de E-value, porcentagem de identidade e comprimento do alinhamento, os hits encontrados seriam considerados significativos? Justifique sua resposta.

4.i.2 - Com base nos resultados desta etapa, em que situações é mais adequado utilizar uma base de dados personalizada em vez de uma base pública (como SwissProt ou nr)? Justifique comparando os resultados observados nas duas abordagens.

- j) (Opcional) Usando o ícone de **Download** () , baixe a base de dados construída e examine a pasta gerada em seu computador, observando a quantidade e as extensões dos arquivos presentes.

Esse passo permite verificar que a base de dados BLAST não corresponde a um único arquivo, mas a um conjunto de arquivos indexados, cada um com uma função específica na estrutura da base.

RELATÓRIO FINAL

Elabore um relatório com base nas respostas, organizando-as de forma clara, com análise e interpretação dos resultados.

REFERÊNCIAS

Pearson WR. An introduction to sequence similarity ("homology") searching. Curr Protoc Bioinformatics. 2013;3:3.1.1–3.1.8. doi:10.1002/0471250953.bi0301s42.

Wheeler DL, Bhagwat M. BLAST QuickStart: Example-driven web-based BLAST tutorial. In: Bergman NH, editor. Comparative genomics: volumes 1 and 2. Totowa (NJ): Humana Press; 2007. Chapter 9. Available from: <https://www.ncbi.nlm.nih.gov/books/NBK1734/>