Laboratório de Bioinformática
IQ-USP

Roteiros Práticos de Bioinformática (QBQ5722)

Da comparação de sequências à análise de microbiomas

Guillermo Uceda Campos

Suzana Eiko Sato Guima

João Carlos Setubal

São Paulo - SP
2026

Sumário

Apresentação **1**

Estrutura dos Roteiros **2**

Primeiros Passos **3**

Roteiro 1: Algoritmos, Ferramentas e Pipelines **5**

Roteiro 2: Comparação de Sequências biológicas **16**

Apresentação

Este material foi desenvolvido a partir das atividades realizadas no Laboratório de Bioinformática do Instituto de Química da Universidade de São Paulo, como um recurso didático organizado em roteiros. Seu principal objetivo é oferecer uma formação prática introdutória em bioinformática e incentivar a participação ativa dos estudantes, centrada no uso de ferramentas e workflows para a análise de sequências biológicas, com base em dados reais de genes, genomas e metagenomas

Para isso, os roteiros orientam, de forma guiada e passo a passo, a realização de exercícios progressivos. Nesses exercícios, os estudantes executam análises reproduzíveis utilizando ferramentas bioinformáticas e configurando seus parâmetros básicos, com aumento gradual de complexidade. Ao longo da prática, são integradas perguntas para reforçar a compreensão, além de acompanhamento em sala para esclarecimento de dúvidas.

Espera-se que os estudantes desenvolvam compreensão do uso de ferramentas bioinformáticas sob a perspectiva do usuário, sendo capazes de aplicá-las na análise de dados em contextos distintos dos apresentados nos roteiros, bem como explorar e propor interpretações a partir dos resultados obtidos.

Os roteiros utilizam diferentes plataformas e ferramentas, sendo a plataforma Galaxy utilizada com maior frequência devido à sua interface intuitiva. Isso facilita o primeiro contato com a área e permite a integração de diferentes ferramentas e a organização de análises em workflows em um único ambiente.

Por fim, para os estudantes que desejarem aprofundar seus estudos, o material oferece sugestões adicionais, que poderão ser revisitadas conforme considerarem mais adequado.

Estrutura dos roteiros

Cada roteiro segue uma estrutura padrão, descrita a seguir:

- **Título e subtítulo**, que contextualizam o tema do roteiro.
- **Leitura introdutória**, apresentada por meio de uma breve metáfora, história ou exemplo científico, com a finalidade de motivar o estudante e introduzir o tema.
- **Objetivos de aprendizagem**, que indicam de forma clara o que se espera que o estudante seja capaz de executar e aplicar ao final do roteiro.
- **Conceitos prévios**, que correspondem a uma breve revisão de conceitos necessários para a realização das atividades propostas no roteiro.
- **Guia passo a passo**, instruções que orientam o estudante na execução das atividades propostas no roteiro. Essas instruções organizam as atividades em etapas numeradas (1, 2, 3, ...), cada uma composta por passos sequenciais: a), b), c), ... Entre os passos, podem ser incluídos:

  Explicativos, com observações sobre o funcionamento das ferramentas, dicas práticas e comentários que auxiliam o aprendizado.

  Perguntas, inseridas ao longo das etapas para orientar a descrição e a análise dos resultados, além de estimular a interpretação crítica dos dados.

  Caixas de parâmetros, solicitados pelas ferramentas e seus respectivos valores. Por exemplo:

  Arquivo de entrada: sequencia1.fasta
  Parâmetro A: 0.5
  Arquivo de saída: resultado.txt
  ▶ ***Run Tool:***

  Pseudocódigo, para visualizar conceitos computacionais sem exigir conhecimento prévio de programação.

  Código, trechos de código em Python explicados para ilustrar sua aplicação prática.

- **Relatório final**, que o aluno entregará ao final de cada aula. Esse deve conter as respostas às perguntas propostas ao longo do guia passo a passo.

Primeiros Passos

- **Acesso ao repositório do Laboratório de Bioinformática**

  O Laboratório de Bioinformática do Instituto de Química da USP, conhecido como Setulab, mantém um repositório no GitHub, que pode ser acessado por meio do seguinte link: GitHub-Setulab

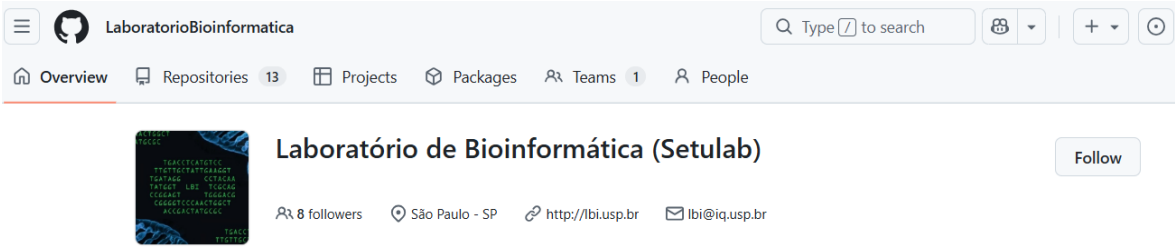

Repositório Setulab - acessado 26 em abril de 2026.

  O GitHub é uma plataforma online utilizada para armazenar, organizar e compartilhar arquivos, permitindo também acompanhar as atualizações do material.

- **Organização do repositório da disciplina**

  O repositório da disciplina QBQ5722 pode ser acessado por meio do link: GitHub-Setulab-bioinformaticsCourse

  A organização do repositório está estruturada em pastas para cada roteiro (`roteiro1`, `roteiro2`, ...), nas quais se encontra o material utilizado em cada atividade. Isso inclui o documento principal "`RoteirosBioinfo.pdf`", que reúne o guia passo a passo de todos os roteiros. Para acessar esse material, recomenda-se baixar a pasta completa de cada roteiro utilizando a ferramenta Download-directory.github. Para isso, copie o link da pasta desejada, cole-o na caixa de entrada ferramenta e realize o download no formato .zip. Em seguida, descompacte o arquivo em seu computador.

- **Conhecendo o Galaxy**

  O Galaxy é uma plataforma de bioinformática que facilita a análise de dados biológicos por meio de uma interface web intuitiva. É amplamente utilizada em áreas como genômica, transcriptômica e metagenômica, pois reúne diversas ferramentas em um único ambiente. A plataforma permite executar análises e construir fluxos de trabalho (workflows), dispensando a necessidade de conhecimentos avançados de programação.

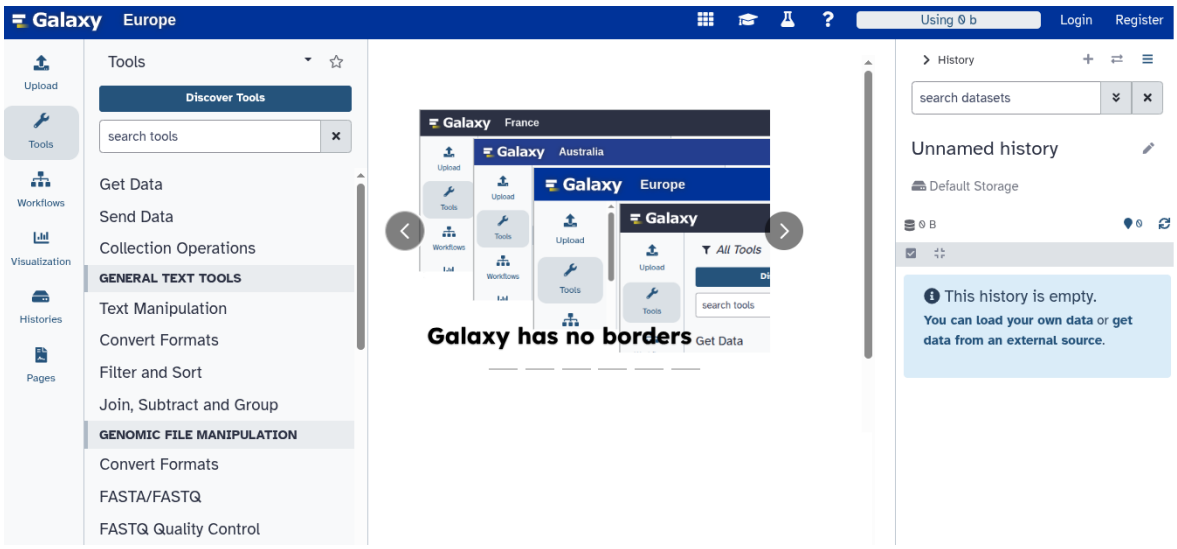

Plataforma Galaxy - acessada em 26 abril de 2026.

- **Criação de uma conta no Galaxy**

  Para utilizar a plataforma Galaxy, é necessário criar uma conta. No canto superior direito do site `https://usegalaxy.eu/`, selecione "Register" no primeiro acesso e informe um e-mail para cadastro. Em seguida, confirme o registro por meio do e-mail recebido e, após a verificação, faça "Login" na plataforma, que oferece acesso gratuito a 250 GB de armazenamento (com possibilidade de expansão).

- **Carregando arquivos no Galaxy**

  Para carregar arquivos no Galaxy, localize o ícone **Upload**( ) no painel lateral esquerdo e selecione **Choose local file**( ). Por exemplo, carregue os arquivos `seq1.fasta` e `seq2.fasta` da pasta "`roteiro1`". Em seguida, clique em **Start** e aguarde até que o upload atinja 100%. Por fim, verifique no painel direito **History** os arquivos aparecem em verde que indica que o processo foi concluído com sucesso.

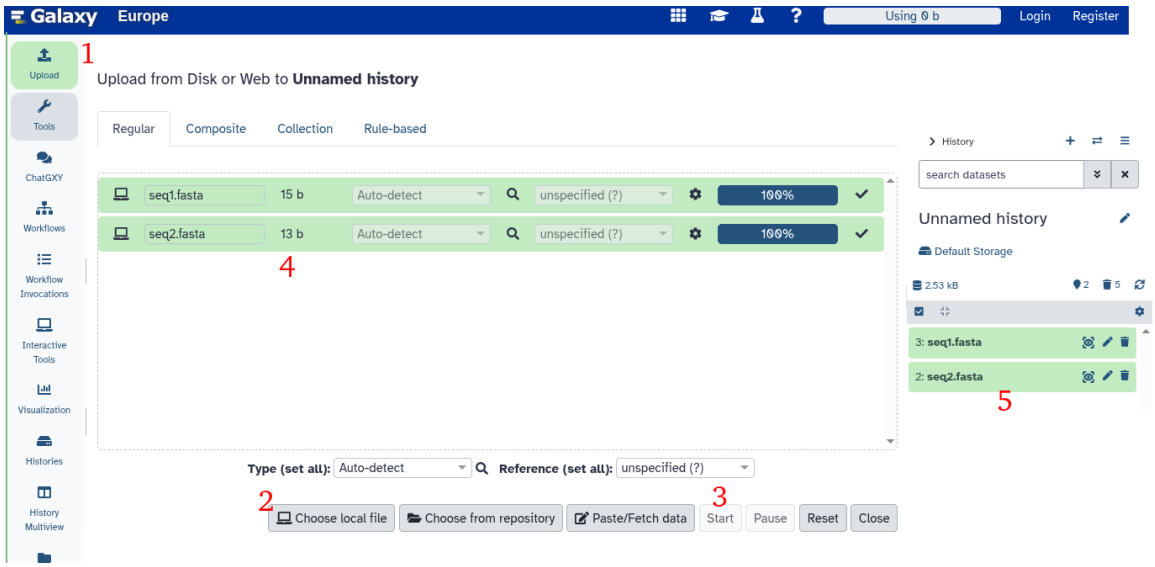

Carregando arquivos no Galaxy desde o computador.

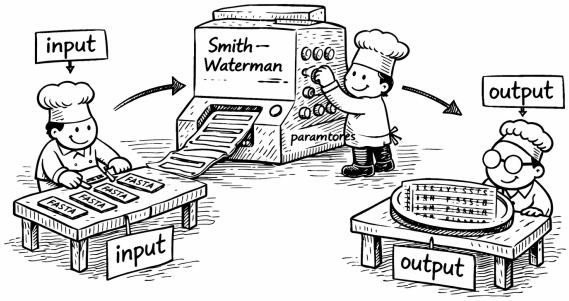

Roteiro 1

Algoritmos, Ferramentas e Pipelines

Introdução aos conceitos fundamentais para análises em Bioinformática

---

A lógica por trás das receitas digitais da bioinformática

Imagine que você está prestes a preparar um bolo especial. Ter os ingredientes certos, como farinha, ovos, leite e açúcar, não é suficiente: é preciso seguir uma sequência de preparo, isto é, uma receita, para obter o resultado desejado. Na bioinformática, podemos estabelecer uma analogia com a cozinha: os dados correspondem aos ingredientes, e o **algoritmo** à receita, que define o modo de preparo e organiza cada etapa.

Existem diferentes algoritmos, cada um com uma função específica, como comparar sequências, montar genomas ou classificar espécies. Cada algoritmo opera seguindo uma lógica interna de etapas, nas quais dados de entrada são processados para gerar uma saída específica. Quando conectamos esses algoritmos, de modo que a saída de um sirva como entrada para o próximo, formamos um **pipeline**, caracterizado por uma sequência linear de etapas. De forma mais geral, esse encadeamento pode ser descrito como um **workflow**, que organiza o processamento, incluindo diferentes dependências entre etapas, e transforma dados brutos em informações biológicas interpretáveis.

Plataformas como o Galaxy tornam esse processo acessível ao permitir não apenas a execução de algoritmos individuais, mas também a organização desses fluxos de trabalho de forma estruturada e reprodutível.

Neste primeiro roteiro, você usará o Galaxy para explorar um dos algoritmos mais fundamentais da bioinformática: o Smith-Waterman, que realiza alinhamentos locais entre sequências, implementado na ferramenta water.

OBJETIVOS

- Compreender a diferença entre algoritmo, ferramenta, pipeline e workflow.
- Executar um alinhamento local (Smith-Waterman) no Galaxy e interpretar seus resultados.
- Construir e reutilizar um workflow no Galaxy, compreendendo o conceito de reprodutibilidade.

CONCEITOS PRÉVIOS

➢ O processo computacional

O processo computacional pode ser descrito, de forma geral, como uma sequência de etapas encadeadas, frequentemente organizado em: **Entrada**, **Processamento** e **Saída**. Na primeira etapa, **Entrada**, são fornecidos os dados que servirão como base para o processo. Esses dados podem ter diferentes naturezas e formatos.

Na segunda etapa, **Processamento**, são aplicadas operações definidas por algoritmos que transformam os dados de entrada. Essas operações podem ser ajustadas por meio de parâmetros, que controlam a forma como o algoritmo é executado.

Por fim, na etapa de **Saída**, são obtidos os resultados do processo, que correspondem aos dados transformados ou às informações derivadas a partir da entrada.

Figura 1: Etapas de um processo computacional

A descrição de um processo computacional pode ser feita em diferentes níveis de abstração. No nível conceitual, o **algoritmo** define os passos necessários para transformar dados de entrada em resultados, independentemente de como será implementado. Essa lógica pode ser representada de forma estruturada por meio de pseudocódigo, facilitando sua compreensão sem depender de uma linguagem de programação específica.

No nível de implementação, o algoritmo pode ser expresso em **código** (por exemplo, scripts em Python), permitindo sua execução por um computador. Um mesmo algoritmo pode ter diferentes implementações, dependendo da linguagem de programação ou da abordagem utilizada.

No nível de uso, uma **ferramenta computacional** disponibiliza essas implementações para uso prático, oferecendo interfaces e parâmetros que possibilitam a execução do processamento sem a necessidade de interação direta com o código.

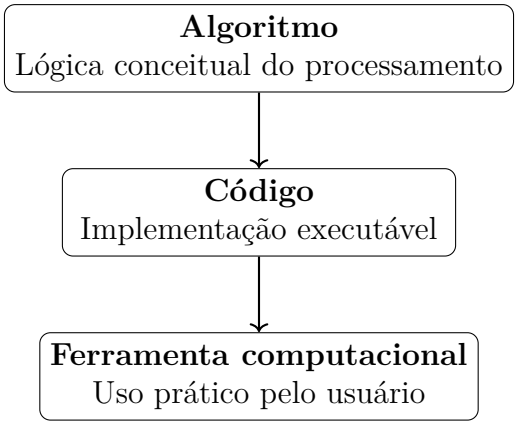

Figura 2: Níveis de abstração no processo computacional.

➢ O processo computacional no Galaxy

Em bioinformática, o termo **pipeline** é utilizado para descrever processos computacionais organizados como uma sequência definida de etapas, na qual cada passo depende do anterior e o fluxo de execução é geralmente linear.

Por outro lado, o termo **workflow**, como utilizado em plataformas como o Galaxy, refere-se a uma representação formal e reutilizável de uma análise, composta por uma série de ferramentas e operações sobre dados executadas de forma automatizada, geralmente em sequência. Nesse contexto, os dados são organizados em **datasets**, que correspondem a arquivos ou conjuntos de dados processados pelas ferramentas, onde a saída de cada etapa serve como entrada da seguinte, favorecendo a reprodutibilidade e a reutilização do processo.

No Galaxy, embora os termos possam se sobrepor em alguns contextos, o termo workflow enfatiza a automação e a reutilização da análise, enquanto pipeline está mais associado a uma estrutura linear de execução.

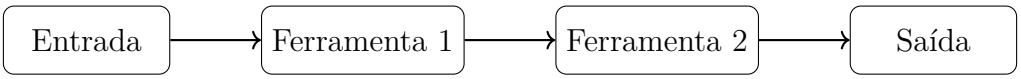

Figura 3: Exemplo esquemático de um workflow no Galaxy.

➢ O Algoritmo smith-waterman

É um algoritmo clássico de programação dinâmica utilizado para realizar alinhamentos locais de sequências biológicas. Pode ser aplicado a sequências de DNA, RNA ou proteínas, com o objetivo de identificar regiões de maior similaridade entre duas sequências.

Durante o alinhamento, pares de posições entre as duas sequências são avaliados por meio de um sistema de pontuação: coincidências (**matches**) recebem valores positivos, enquanto diferenças (**mismatches**) e lacunas (**gaps**) são penalizadas.

Com base nesse sistema de pontuação, o algoritmo constrói uma matriz, na qual cada posição representa a melhor pontuação possível para um alinhamento local até essa posição. A partir dessa matriz, é possível identificar o alinhamento local com a maior pontuação.

Exemplo: Considere o seguinte alinhamento obtido pelo algoritmo de Smith–Waterman:

```
Sequência_1:  CTCT--CTGATAAG
              |||.  |.||.|||
Sequência_2:  CTCCTGCCGACAAG
```

Os símbolos utilizados no alinhamento são: `|`, que indica um **match**; `.`, que indica um **mismatch**; e `-`, que indica um **gap**.

GUIA PASSO A PASSO

1. A lógica de um algoritmo e sua implementação

Nesta primeira etapa, você irá explorar o processo computacional de alinhamento de sequências. O foco será compreender como esse processo se organiza em termos de entrada, processamento e saída, sendo que o algoritmo **smith-waterman** é tomado como base na etapa de processamento.

Inicialmente, os passos do algoritmo serão representados em pseudocódigo, proporcionando uma visão mais estruturada de seu funcionamento. Em seguida, será apresentada sua implementação em Python, para observar como a lógica do algoritmo é implementada em código.

a) Leia atentamente as etapas do processo computacional para alinhamento de sequências. Em seguida, foque na etapa de processamento, que apresenta os passos do algoritmo smith-waterman.

ENTRADA

1. Definir as duas sequências de entrada
2. Definir o sistema de pontuação

PROCESSAMENTO

3. Construir a matriz de pontuação com dimensões baseadas nas sequências de entrada
4. Inicializar a matriz com valores das penalidades de gap
5. Preencher a matriz considerando as transições diagonal, superior e lateral, aplicando o critério de máximo.
6. Identificar o maior valor em toda a matriz
7. Realizar o traceback a partir do maior valor encontrado, até atingir uma célula com valor zero

SAÍDA

8. Mostrar o alinhamento local reconstruído

O **traceback** é o processo de percorrer a matriz no sentido inverso para identificar como o alinhamento foi construído. A partir da última célula, segue-se o caminho de maior pontuação até o início, reconstruindo o alinhamento passo a passo.

b) Observe agora a representação do algoritmo smith-waterman em pseudocódigo.

Algorithm 1: Algoritmo smith-waterman para alinhamento local

Entrada: Sequências seq1 e seq2;
Parâmetros de pontuação (match, mismatch, gap)
Saída : Alinhamento local

1 $rows \leftarrow$ tamanho de seq2 + 1
2 $cols \leftarrow$ tamanho de seq1 + 1
3 $matrix \leftarrow$ matriz de tamanho $rows \times cols$
4 Inicializar a primeira linha e a primeira coluna de *matrix* com penalidades de gap;
5 **Para cada** *linha i, de 1 até* $rows - 1$ **faça**
6 | **Para cada** *coluna j, de 1 até* $cols - 1$ **faça**
7 | | $diagonal \leftarrow matrix[i-1][j-1] + (match$ se $seq2[i-1] = seq1[j-1]$; caso contrário $mismatch)$
8 | | $cima \leftarrow matrix[i-1][j] + gap$
9 | | $esquerda \leftarrow matrix[i][j-1] + gap$
10 | | $matrix[i][j] \leftarrow \max(diagonal, cima, esquerda)$
11 | **fim**
12 **fim**
13 Iniciar na célula com o maior valor de toda a matriz
14 **Enquanto** *não chegar à célula inicial* **faça**
15 | identificar a direção (diagonal, cima ou esquerda) que gerou o valor da célula
16 | atualizar o alinhamento adicionando caracteres correspondentes ou gaps
17 **fim**
18 Mostrar o alinhamento local reconstruído

Um **pseudocódigo** é uma forma estruturada de descrever a lógica de um algoritmo, utilizando uma linguagem próxima à programação, mas voltada à compreensão humana e independente de uma linguagem específica.

1.b - Complete a correspondência entre os passos do algoritmo smith-waterman na etapa processamento e as linhas do pseudocódigo. Em seguida, justifique cada associação explicando por que essas linhas representam aquele passo, com base na lógica do algoritmo.

Smith-Waterman	Pseudocódigo	Justificativa
3. Construir matriz 4. Inicializar matriz 5. Preencher matriz 7. Realizar traceback	1-3	...

c) Acesse o link abaixo e analise o script que implementa o algoritmo:

smith-waterman-algorithm.py

Um script é um arquivo que contém instruções escritas em uma linguagem de programação, seguindo uma sintaxe específica que permite sua execução por um computador.

d) No script, localize as linhas que começam com o caractere "#", que indicam comentários no código, e observe as explicações associadas.

As linhas iniciadas por "#" são chamadas de comentários. Elas não são executadas pelo programa, mas ajudam a explicar o que o código faz, sendo úteis para a leitura e compreensão por outras pessoas.

e) Localize no script o bloco de código correspondente às linhas 37 a 41:

```
37 def smith_waterman(seq1, seq2):
38     # Generating the empty matrices for storing scores and ...
39     row = len(seq1) + 1
40     col = len(seq2) + 1
41     matrix = np.zeros(shape=(row, col), dtype=np.int)
```

Uma função em Python é um bloco de código que realiza uma tarefa específica e pode ser reutilizado várias vezes dentro de um programa. A definição de uma função segue o formato:

```
def funcao(param1, param2)
```

Os parênteses podem conter parâmetros, como `param1, param2`. Eles representam os valores de entrada da função utilizados durante sua execução.

1.e - Na função `smith_waterman`. O que representam os parâmetros `seq1` e `seq2`, e as variáveis `row` e `col`? Qual funcionalidade do algoritmo corresponde às linhas 39–41? Justifique sua resposta.

f) Agora, observe o bloco de código das linhas 49 a 59, responsável pelo preenchimento da matriz de pontuação no algoritmo de smith-waterman:

```
49 for i in range(1, row):
50     for j in range(1, col):
51         # Calculating the diagonal score (match score)
52         match_value = Score.MATCH # ...
53         diagonal_score = matrix[i - 1, j - 1] + match_value
54
55         # Calculating the vertical gap score
56         vertical_score = matrix[i - 1, j] + Score.GAP
57
58         # Calculating the horizontal gap score
59         horizontal_score = matrix[i, j - 1] + Score.GAP
```

1.f - Observe o uso de duas instruções "`for`" nas linhas de código e as três variáveis `diagonal_score`, `vertical_score` e `horizontal_score`. O que isso indica sobre a forma como a matriz é percorrida e preenchida? Por que essa abordagem é necessária para o algoritmo? Justifique.

2. Explorar ferramentas prontas para uso

Nesta etapa, você irá explorar como algoritmos são utilizados na prática por meio de ferramentas computacionais. O algoritmo **smith-waterman**, estudado na etapa anterior, será aplicado com a ferramenta **water**, disponível na plataforma Galaxy

a) Faça login na plataforma Galaxy com seu usuário cadastrado.

> Caso ainda não tenha criado sua conta, siga as instruções para cadastro descritas na seção Primeiros Passos.

b) Utilize a ferramenta Download-directory.github para baixar a pasta `roteiro1`, como indicado na seção Primeiros Passos.

c) Carregue os arquivos `seq1.fasta` e `seq2.fasta` a partir da pasta `roteiro1` usando o ícone Upload ( )como indicado na seção Primeiros Passos.

d) Procure a ferramenta **water** usando o icone **Tools** ( ). Na sequência, configure os parâmetros conforme indicado a seguir:

> ***Sequence 1:*** seq1.fasta
> ***Sequence 2:*** seq2.fasta
> ***Gap open penalty:*** 10.0
> ***Gap extension penalty:*** 0.5
> ***Output alignment file format:*** SRS pair (m)
>
> ***Run Tool:***

e) O resultado da análise anterior aparecerá no painel History, em um arquivo cujo nome estará relacionado à análise realizada. Aguarde a execução das análises, pendente em History, e depois renomeie o arquivo para `smith_default.txt` usando o ícone **Edit Attributes** ( ) e salve as alterações usando o ícone **Save**( ).

> No Galaxy, todos os arquivos utilizados e gerados em uma análise são registrados no painel History. Cada arquivo recebe uma identificação automática, mas seus nomes podem ser ajustados para facilitar a organização dos resultados.

f) Visualize os resultados gerados clicando no ícone View ( ).

> 2.f - Qual foi o resultado obtido (número de colunas no alinhamento, score e parâmetros)? Faça um print da tela desse resultado. O que esses valores indicam sobre a similaridade entre as sequências? Justifique.

g) Execute novamente **water**, mas agora considerando os seguintes parâmetros::

> ***Sequence 1:*** seq1.fasta
> ***Sequence 2:*** seq2.fasta
> ***Gap open penalty:*** 2
> ***Gap extension penalty:*** 1
> ***Output alignment file format:*** SRS pair (m)
>
> ***Run Tool:***

h) Renomeie o arquivo gerado para `smith_open2exten1.txt` e salve as alterações, conforme descrito em (e). Observe os novos resultados, conforme descrito em (f)

> 2.h - Como a mudança dos parâmetros alterou o resultado do alinhamento? Faça um print da tela desse resultado. O que você observa em termos de *matches*, *mismatches* e *gaps*? Como essas diferenças impactam a interpretação biológica? Justifique.

i) (Opcional) Tente reproduzir os resultados usando a ferramenta iterativa Global Alignment App e usando as mesmas sequências.

3. Execução sequencial de ferramentas e construção de um workflow

Nesta etapa, você executará diferentes ferramentas de forma sequencial no Galaxy, simulando um fluxo de análise. O objetivo é mostrar como essas etapas podem ser integradas em um processo reprodutível, que posteriormente será exportado como um workflow. As ferramentas utilizadas e sua ordem de execução são apresentadas a seguir:

a) Carregue e visualize o arquivo **seqs_trxA.fasta** no painel History. Clique no ícone *View* e, em seguida, na seção *Details*. Observe como o arquivo carregado é identificado no Galaxy.

> No Galaxy, **Datasets** ( ) correspondem aos dados de entrada e saída de cada etapa de uma análise. Isso significa que todo arquivo carregado ou gerado por uma ferramenta é considerado um dataset, podendo ser reutilizado em etapas seguintes do fluxo de análise.

b) A primeira ferramenta a ser utilizada é o **SeqKit statistics**, que obtém estatísticas de um arquivo FASTA. Procure a ferramenta e configure seus parâmetros conforme indicado a seguir.

> ***Input file:*** seqs_trxA.fasta
> ***Output all statistics:*** No
> ***Output base name of input file:*** No
> ▶ ***Run Tool:***

> 3.b - Observe o arquivo gerado. Qual é o seu formato e que tipo de sequências ele contém? O que as características observadas indicam sobre os dados analisados? Justifique.

c) A segunda ferramenta é o **transeq**, que realiza a tradução das sequências de nucleotídeos em aminoácidos. Procure a ferramenta e configure seus parâmetros conforme indicado abaixo. Em seguida, renomeie o dataset gerado para "`trxA_prt.fasta`" e salve as alterações.

> ***Sequences:*** seqs_trxA.fasta
> ***Frame(s) to translate:*** Frame 1
> ***Code to use:*** Bacteria
> ***Output sequence file formate:*** FASTA (m)
> ▶ ***Run Tool:***

d) A terceira ferramenta é o **pepstats**, que calcula estatísticas básicas de sequências proteicas. Procure a ferramenta e configure seus parâmetros conforme indicado abaixo. Em seguida, renomeie o arquivo gerado para "`trxA_prt_pepstats.txt`" e salve as alterações.

> ***Sequences:*** trxA_prt.fasta
> ***Include charge at N and C terminus:*** No
> ▶ ***Run Tool:***

3.d - Quais são as propriedades obtidas das sequências (resíduos, peso molecular, carga e ponto isoelétrico)? O que essas propriedades sugerem sobre as características das sequências? Justifique.

e) A quarta ferramenta é o **Split Fasta**, que separa as sequências em arquivos FASTA individuais. Procure a ferramenta e configure seus parâmetros conforme indicado a seguir.

> ***Sequences:*** trxA_prt.fasta
> ***Split mode:*** Each sequence in its own dataset
> ▶ ***Run Tool:***

f) O resultado da etapa anterior gera uma *collection*, que agrupa vários *datasets*, cada um correspondendo a uma sequência no formato FASTA. Observe que esses *datasets* recebem como nome o ID da sequência e mantêm o formato original.

No Galaxy, uma **collection** agrupa vários datasets em um único objeto, permitindo que ferramentas sejam aplicadas a todos eles de forma conjunta, o que torna a análise mais rápida e organizada.

g) Por fim, a última ferramenta a ser utilizada é o **water**, que utilizará os *datasets* gerados na etapa anterior. Procure a ferramenta e configure seus parâmetros conforme indicado abaixo. Para acessar os *datasets*, é necessário clicar no ícone *Browse or Upload Datasets* (•••) e, em seguida, localizar a coleção de *datasets*, representada como uma pasta.

Sequence 1: Split Fasta on dataset Sent_trxA_1
Sequence 2: Split Fasta on dataset Ecol_trxA_1
Output alignment file format: FASTA (m)
▶ ***Run Tool:***

3.g - Qual foi o resultado obtido desta vez? Descreva-o. O que muda em relação ao formato anterior gerado pela ferramenta water? Em que situações esse formato é mais adequado? Justifique.

h) Agora vamos exportar o workflow. No painel History, localize o ícone **History options** (☰), clique nele e selecione **Extract Workflow**. Na janela que será aberta, atribua um nome ao workflow.

Observe que são exibidas duas colunas: uma com as ferramentas utilizadas e outra com os itens do History (*datasets* e *collections*). Selecione apenas os items a partir de **seqs_trxA.fasta**; isso implica desmarcar os demais. Em seguida, clique em **Create Workflow**.

i) Para visualizar o workflow criado, localize o ícone **Workflows** (⚭) no painel da direita, clique na aba *My workflows* e, na lista exibida, localize seu workflow. Em seguida, clique nele para visualizá-lo.

j) (Opcional) Navegue pelos repositórios do Github de **Snakemake** e **Nextflow**, alternativas robustas para a construção e execução de pipelines bioinformáticos que, no entanto, exigem maior familiaridade com linha de comando, programação e organização de ambientes computacionais. Explore a documentação disponível nos repositórios oficiais:

- `https://github.com/snakemake/snakemake`
- `https://github.com/nextflow-io/nextflow`

Diferentemente do Galaxy, essas ferramentas são voltadas principalmente para execução em ambientes locais ou de computação de alto desempenho (HPC) e são amplamente utilizadas em projetos de pesquisa que exigem maior flexibilidade e escalabilidade.

4. Navegar pelos workflows do Galaxy e outras funcionalidades

Como visto na etapa anterior, o Galaxy permite criar, executar e exportar workflows. Além disso, a plataforma disponibiliza workflows públicos, desenvolvidos e compartilhados pela comunidade. Nesta etapa, o objetivo é explorar esses workflows.

a) Localize o ícone **Workflows** no painel da direita. Explore as abas *Workflows shared with me* e *Public Workflows*.

b) Na aba *Public Workflows*, você encontrará workflows para diferentes aplicações. Utilize o campo de busca para procurar workflows voltados à montagem de genomas bacterianos, considerando os seguintes critérios:

Search: Bacterial Genome Assembly
Sort by: Update time
Sort by: Name

4.b - Após realizar a busca conforme as instruções, escolha um workflow recente (preferencialmente na versão mais atual) e analise-o. Faça um print do workflow selecionado. Como ele está organizado (entrada, etapas e saída)? O que essa organização revela sobre o processo de análise? Justifique sua resposta.

c) Outros recursos de visualização oferecidos pelo Galaxy podem ser acessados por meio de **Visualization** ( ). Para explorar essa funcionalidade aplicada ao alinhamento de sequências, clique em *Visualization* e procure a ferramenta **Multiple Sequence Alignment and Sequence Logo**. Em seguida, configure seus parâmetros conforme indicado a seguir:

Select to Visualize: trxA_prt.aln

4.c - Qual ferramenta de visualização você escolheu? Que tipo de informações o visualizador apresenta? Como essas informações contribuem para a interpretação dos dados analisados? Justifique sua resposta.

d) Para complementar seus estudos, saiba que além de *Visualization*, o Galaxy também oferece a interação com outros ambientes computacionais por meio de **Interactive Tools** ( ). As ferramentas disponibilizadas no *Interactive Tools* permitem o uso de terminais, notebooks, entre outros, úteis para análises exploratórias, visualizações dinâmicas e execução de código personalizado.

O **Iterative JupyterLab Notebook** é uma das opções mais utilizadas para execução de código no Galaxy. Ele permite executar scripts diretamente nesse ambiente, como aquele apresentado na etapa 1. Dessa forma, é possível implementar um algoritmo e executá-lo no próprio Galaxy, sem a necessidade de ferramentas externas.

RELATÓRIO FINAL

Elabore um relatório com base nas respostas, organizando-as de forma clara, com análise e interpretação dos resultados.

REFERÊNCIAS

Afgan, E., Baker, D., Coraor, N. et al. Galaxy CloudMan: delivering cloud compute clusters. *BMC Bioinformatics*, 2010.

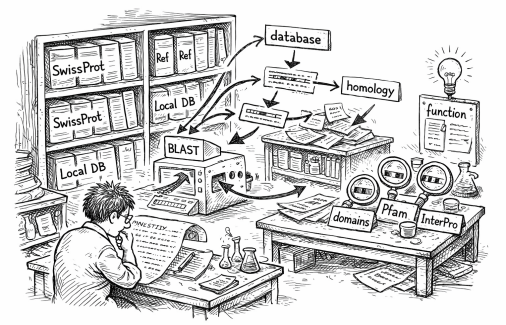

Roteiro 2

Comparação de Sequências biológicas

Busca de sequências semelhantes e identificação de homólogos

Por que precisamos descobrir a função de genes novos?

Imagine que você encontra uma frase misteriosa escrita em uma língua antiga que você não conhece. Um primeiro passo natural seria buscar padrões ou trechos semelhantes em textos já catalogados, na tentativa de obter pistas sobre seu significado. Na bioinformática, seguimos uma lógica parecida. Quando buscamos compreender a função de um gene ou proteína ainda desconhecidos, comparamos sua sequência com milhões de outras já anotadas em bancos de dados públicos, procurando similaridades que possam indicar relações funcionais ou evolutivas. Ferramentas como o BLAST funcionam como um "Google das sequências biológicas", permitindo identificar sequências semelhantes a uma sequência desconhecida e reconhecer seus "parentes" mais próximos. A partir dessas semelhanças, é possível levantar hipóteses sobre sua função e relacioná-la a contextos biológicos relevantes, como resistência a antibióticos, reconhecimento de hospedeiros, virulência ou toxicidade. Neste roteiro, você irá, passo a passo, descobrir a função provável de uma proteína, interpretar os resultados obtidos e aprender a sustentar hipóteses funcionais a partir de evidências estatísticas e biológicas.

OBJETIVOS

- Executar buscas de similaridade utilizando BLASTp em bases locais e públicas.
- Interpretar métricas estatísticas (e-value, bit-score, identidade, cobertura).
- Avaliar o impacto de parâmetros do BLAST nos resultados.
- Integrar evidências de similaridade e domínios conservados para propor hipóteses funcionais.